

Módulo scRNA-seq + CITE-seq y anotación celular

Bioinformática y Estadística 3 · Licenciatura en Ciencias Genómicas · Semestre 2027-1

Docente invitado: Dr. Danilo Ceschin

Cuatro clases: martes 8, jueves 10, martes 22 y jueves 24 de septiembre de 2026 · 12:30 a 14:30 h

Modalidad: en línea · Entorno de trabajo: RStudio Server en el clúster ken, o R + RStudio en tu computadora

1. De qué se trata este módulo

Cuando terminaste el módulo anterior tenías una matriz de conteos limpia: células que pasaron el control de calidad, genes detectados, dobletes descartados. Eso es el punto de partida, no el resultado.

Estas cuatro clases recorren el camino que va desde esa matriz hasta una afirmación biológica: *"este grupo de células son monocitos CD14+ y estos genes los distinguen"*. El recorrido tiene cuatro etapas, y cada una es una clase.

Clase	Fecha	Tema	La pregunta que responde
1	mar 8-sep	Normalización, escalamiento y reducción de dimensionalidad	¿Cómo hago comparables dos células que se secuenciaron con distinta profundidad?
2	jue 10-sep	Clustering y expresión diferencial	¿Cómo agrupo células parecidas, y qué puedo afirmar estadísticamente sobre esos grupos?
3	mar 22-sep	Anotación celular	¿Cómo le pongo nombre biológico a un grupo, y con cuánta confianza?
4	jue 24-sep	CITE-seq y análisis multimodal	¿Qué agrega medir proteína de superficie en las mismas células?

Entre la clase 2 y la clase 3 hay doce días. En el medio tienes la clase de efectos de lote (15-sep) y la presentación de equipos (17-sep), así que hay tiempo de sobra para releer los scripts de las dos primeras clases antes de la anotación.

Lo que este módulo quiere que te lleves

No es una lista de funciones de Seurat. Es un criterio. Las cuatro clases están armadas alrededor de una misma idea incómoda:

Casi todos los pasos de un análisis de célula única son decisiones, no cálculos. Cuántos genes variables usar, cuántas componentes principales, qué resolución de clustering, qué umbral de confianza para una anotación. Ninguna tiene un valor correcto universal. Lo que este módulo busca es tu capacidad de **tomar esas decisiones con criterio y defenderlas**, no de llegar a un número particular.

Por eso, cuando en clase se discuta una elección, lo que importa es el argumento y no el número. Un análisis con una elección discutible bien argumentada vale más que uno con la elección "correcta" sin explicación.

2. Qué se asume que ya sabes

Este módulo asume que ya trabajaste con estos temas:

- Manejo básico de R y del tidyverse.
- Qué es una matriz de conteos de célula única, cómo se genera (FASTQ → cuantificador → matriz) y qué estructura tiene.
- Control de calidad: métricas por célula, umbrales fijos vs adaptativos por MAD, detección de dobletes.
- La diferencia entre réplica biológica y réplica técnica, y por qué la célula no es la unidad de réplica.

Nada de esto hace falta traerlo resuelto en un archivo. El módulo usa **su propio conjunto de datos** y hace **su propio control de calidad**: la clase 1 incluye un bloque ejecutable de unos 10 minutos que descarga la matriz y la filtra desde cero. No es un repaso teórico, es código que corre y que puedes volver a leer después.

3. Los datos

Vamos a usar **un único conjunto de datos durante las cuatro clases**: PBMC (células mononucleares de sangre periférica) de un donante sano, procesadas por 10x Genomics con el kit *Cell Surface Protein* (TotalSeq-B).

El archivo contiene **dos modalidades medidas sobre exactamente las mismas células**:

Modalidad	Qué es	Cuándo la usamos
Gene Expression	33.538 genes, conteos de ARNm	clases 1, 2 y 3
Antibody Capture	17 anticuerpos con oligo (ADT)	clase 4

Que sea el mismo dataset en las cuatro clases no es comodidad: es el punto. En la clase 4 vas a conocer las poblaciones celulares desde hace dos semanas, y vas a poder preguntarte si la proteína **confirma o corrige** lo que dijo el ARN. Esa comparación es la mitad del contenido de esa clase.

Los scripts descargan los datos solos, de una URL pública y estable de 10x Genomics. No hace falta que bajes nada a mano.

Archivo	Tamaño	Se usa en
<code>pbmc10k_filtered.h5</code>	~21 MB	clases 1 a 4
<code>pbmc10k_raw.h5</code>	~154 MB	solo clase 4

4. Preparación: hazlo antes de la primera clase

La primera vez que se instalan Seurat y sus dependencias puede tardar entre 20 minutos y una hora, según tu computadora y tu conexión. **Si lo dejas para el 8 de septiembre a las 12:30, vas a perderte la mitad de la clase.**

Paso 1 • R y RStudio

Necesitas **R 4.3 o superior** y RStudio. Si ya los tienes, verifica la versión con `R.version.string` en la consola.

Paso 2 • Dependencias del sistema (fuera de R)

Este paso se hace una sola vez y es el que más problemas da. El paquete `hdf5r`, que es el que lee los archivos `.h5` de 10x, necesita la biblioteca HDF5 instalada en el sistema operativo.

macOS — en la Terminal:

```
xcode-select --install
brew install hdf5
```

(Si no tienes Homebrew, instálalo desde [brew.sh](#).)

Linux (Debian/Ubuntu) — en la terminal:

```
sudo apt install libhdf5-dev libcurl4-openssl-dev libssl-dev libxml2-dev \
    libfontconfig1-dev libharfbuzz-dev libfribidi-dev
```

Windows — instala [Rtools](#) de la misma versión mayor que tu R (para R 4.4.x, Rtools44).

Paso 3 • El proyecto

- Descarga y descomprime la carpeta del curso donde te resulte cómodo. **No la pongas dentro de una carpeta sincronizada con OneDrive, Dropbox o Google Drive:** los archivos intermedios pesan cientos de MB y la sincronización se vuelve un problema.
- Doble clic en `Curso_scRNAseq.Rproj`. RStudio abre el proyecto y fija el directorio de trabajo. Sin este paso las rutas relativas no funcionan y los datos terminan en cualquier lado.
- Abre `Clase1_Normalizacion_y_Reduccion_de_Dimensionalidad.R` y ejecuta **solo la sección 0** (instalación). Ve a hacer otra cosa mientras corre.

Paso 4 • Verificación

Cuando la sección 0 termine, en la consola tendría que aparecer algo como:

```
Seurat: 5.5.1
R: R version 4.4.x ...
```

Si llegaste hasta aquí sin errores, estás listo. **Si algo falló, escribe antes de la clase**, no el día de la clase.

Cómo trabajar con los scripts

- Ejecuta **línea por línea** con `Ctrl+Enter` (`Cmd+Enter` en macOS). No corras el archivo entero de una sola vez: el objetivo es mirar cada resultado.
- `Ctrl+Shift+0` abre el índice de secciones, que es la forma rápida de moverse por el script.
- Los gráficos van al panel *Plots*. Usa el botón **Zoom** para verlos en grande.
- Todo el texto explicativo está en el propio script, como comentarios. Los scripts están pensados para poder releerse solos, sin la clase.

El documento HTML de cada clase

Además del script, de cada clase recibes un archivo `.html`: es **ese mismo código ya ejecutado**, con sus resultados y sus figuras tal como salieron.

Úsalo de dos maneras. Durante la práctica, para comparar: si tu salida no se parece a la del documento, algo pasó y conviene mirarlo antes de seguir. Y después de la clase, para estudiar, porque tiene el texto explicativo y los resultados juntos.

Para trabajar se usa siempre el `.R`. El documento es una referencia, no un reemplazo.

5. Cómo es cada clase

Las cuatro clases tienen la misma estructura:

Tiempo	Bloque
5 min	Encuadre: dónde estamos en el pipeline y de qué se parte
~40 min	Teoría, con la presentación
~65 min	Práctica guiada sobre el script, todos ejecutando
10 min	Síntesis y cierre

La práctica es **guiada**: ejecutamos juntos y nos detenemos a discutir en los puntos donde hay una decisión que tomar. No es un taller de trabajo autónomo. Trae la computadora con el entorno ya instalado.

El encadenamiento entre clases

Cada clase guarda un archivo `.rds` con el objeto de trabajo en la carpeta `results/`, y la clase siguiente lo lee de ahí:

```
Clase 1 → clase1_pbmc_reducido.rds
Clase 2 → clase2_pbmc_clusterizado.rds
Clase 3 → clase3_pbmc_annotado.rds
Clase 4 → clase4_pbmc_multimodal.rds
```

Si te perdiste una clase o borraste algo, **no pasa nada**: cada script tiene un bloque de regeneración que reconstruye el objeto desde cero en 4 o 5 minutos. Está marcado como *OPCIÓN B* y se ejecuta solo si el archivo anterior no aparece.

6. Preguntas frecuentes

No me instala hdf5r. Es el problema más común y casi siempre es el paso 2: falta la biblioteca HDF5 del sistema. Revisa esa sección. Si aun así no compila, avisa: hay una alternativa que baja la matriz en otro formato y usa `Read10X()` en lugar de `Read10X_h5()`.

¿Cuánta RAM necesito? Con 8 GB alcanza para las clases 1 a 3. La clase 4 carga la matriz cruda completa —6.794.880 códigos de barras— y ahí conviene tener 16 GB. Si tienes 8, cierra todo lo demás y corre `gc()` entre secciones; funciona, pero queda ajustado.

¿Puedo usar Python / scanpy en lugar de R? El módulo está en R con Seurat, y las clases se dictan sobre ese código. Si prefieres reproducir el análisis en scanpy por tu cuenta, adelante: los conceptos son los mismos. En clase seguimos el código en R.

Me perdí una clase. Los scripts se leen solos: todo el texto explicativo está adentro. Corre el bloque de regeneración de la clase siguiente y sigue. Después consulta lo que no haya quedado claro.

¿Conviene versionar los .rds con git? No. Pesan cientos de MB. La carpeta ya trae un `.gitignore` que excluye `data/`, `results/` y `figures/`; se versiona el código, no los objetos.

7. Recursos

Documentación

- Seurat v5 — viñetas oficiales: satijalab.org/seurat
- Single-cell best practices (Theis lab): sc-best-practices.org
- CZ CELLxGENE Discover y CellGuide: cellxgene.cziscience.com
- Cell Ontology: obophenotype.github.io/cell-ontology

Lecturas críticas (no hace falta leerlas completas; las discutimos en clase)

- Squair J. *et al.* **Confronting false discoveries in single-cell differential expression.** *Nat Commun* 2021. — El argumento a favor de pseudobulk. Para la clase 2.
- Neufeld A. *et al.* **Count splitting** — inferencia válida después de clustering. Para la clase 2.
- Mulè M. *et al.* **dsb: normalización y denoising de datos de proteína en gotas.** *Nat Commun* 2022. Para la clase 4.
- Zheng Y. *et al.* **ADTnorm.** *Nat Commun* 2025. Para la clase 4.

Cualquier problema con la instalación, escríbeme antes de la primera clase. Es literalmente la única parte de este módulo que no tiene sentido resolver en el aula.

Nota de la coordinación del curso · 11 de septiembre de 2026

Este documento es del Dr. Danilo Ceschin. Se corrigieron tres datos operativos que no coincidían con el curso: el horario (decía 12:00 a 14:00; es 12:30 a 14:30), la modalidad (decía híbrida; es en línea) y el entorno de trabajo. El contenido del módulo no se tocó. Sobre el entorno: el grupo tiene acceso a RStudio Server en el clúster ken, con los paquetes ya instalados, y es la vía recomendada. Trabajar en tu propia computadora sigue siendo válido: el manual del curso explica ambas.